

Отчет о выполнении проекта

По дисциплине: «Анализ данных»

На тему: «Анализ фитнес-активностей пользователей трекера»

Выполнил: студент группы БИ-2302 Аксенкина В.А.

Принял: старший преподаватель кафедры
прикладной математики и экономико-
математических методов Вилло Н.Ю.

Санкт-Петербург

2025

1. Цель исследования

Целью анализа является приобретение навыков исследования данных на примере фитнес-активностей пользователей, включая изучение демографических характеристик, паттернов тренировок, физиологических показателей и их взаимосвязей для выявления тенденций в поведении пользователей фитнес-трекера.

2. Перевод, смысл данных в каждом столбце

- **record_id** - порядковый номер записи о тренировке
- **timestamp** - дата и время проведения тренировки
- **user_id** - уникальный идентификатор пользователя
- **age** - возраст пользователя в годах
- **gender** - пол пользователя (Male/Female/Other)
- **activity_type** - тип физической активности (Йога, Бег, Плавание и др.)
- **duration_min** - продолжительность тренировки в минутах
- **calories_burned** - количество сожженных калорий за тренировку
- **heart_rate_avg** - средняя частота пульса во время тренировки (уд/мин)
- **steps** - количество пройденных шагов за день
- **sleep_hours** - продолжительность сна пользователя в часах
- **weight_kg** – масса тела пользователя в килограммах

3. Качественные признаки

Временная метка проведения тренировки (**timestamp**) является категориальным признаком, представленным в формате даты и времени. Всего в датафрейме содержится 200 записей, из которых 199 имеют уникальные значения временных меток. Только одна временная метка повторяется дважды - 2025-07-08 21:56:54, что составляет 1% от общего количества записей. В данном столбце отсутствуют пропуски. Распределение временных меток демонстрирует высокую степень уникальности - 99.5% всех временных отметок встречаются только один раз. Данные охватывают период с мая по октябрь 2025 года.

```
df['timestamp'].describe()
```

	timestamp
count	200
unique	199
top	2025-07-08 21:56:54
freq	2
dtype: object	

Рис. 1 Описание признака timestamp

`df['timestamp'].value_counts()`

timestamp	count
2025-07-08 21:56:54	2
2025-05-28 13:53:54	1
2025-07-22 09:22:54	1
2025-07-17 01:56:54	1
2025-08-11 03:22:54	1
...	...
2025-05-28 13:00:54	1
2025-10-10 22:31:54	1
2025-06-12 04:53:54	1
2025-10-11 21:37:54	1
2025-07-11 04:47:54	1

199 rows x 1 columns

dtype: int64

`df['timestamp'].value_counts(normalize=True)`

timestamp	proportion
2025-07-08 21:56:54	0.010
2025-05-28 13:53:54	0.005
2025-07-22 09:22:54	0.005
2025-07-17 01:56:54	0.005
2025-08-11 03:22:54	0.005
...	...
2025-05-28 13:00:54	0.005
2025-10-10 22:31:54	0.005
2025-06-12 04:53:54	0.005
2025-10-11 21:37:54	0.005
2025-07-11 04:47:54	0.005

199 rows x 1 columns

Рис. 2 Подсчет уникальных значений




Рис. 3 Круговая диаграмма распределения временных меток

Вторым категориальным признаком является идентификатор пользователя (**user_id**), представляющий уникальных пользователей фитнес-трекера. В данном столбце отсутствуют пропуски. Всего в датафрейме представлено 49 уникальных пользователей. Распределение записей по пользователям неравномерное. Наиболее активные пользователи U030 и U011 составляют по 4.5% от всех записей (по 9 записей каждый). Далее следуют пользователи U026 и U035 - по 3.5% (по 7 записей). Группа умеренно активных пользователей (U039, U028, U049) составляет по 3% записей (по 6 записей каждый). Около 65% пользователей имеют от 3 до 9 записей, что указывает на регулярное использование фитнес-трекера. При этом 6 пользователей (12% от общего количества) представлены всего одной записью.

```
df['user_id'].describe()
```

user_id	
count	200
unique	49
top	U030
freq	9

dtype: object

Рис. 4 Описание признака user_id

```
df['user_id'].value_counts()
```

user_id	count
U030	9
U011	9
U026	7
U035	7
U039	6
U028	6
U049	6
U034	5
U019	5
U050	5
U038	5

```
df['user_id'].value_counts()
```

U025	5
U023	5
U008	5
U013	5
U041	5
U021	5
U004	4
U022	4
U001	4
U033	4
U014	4
U015	4
U031	4

```
df['user_id'].value_counts(normalize=True)
```

	proportion
user_id	
U030	0.045
U011	0.045
U026	0.035
U035	0.035
U039	0.030
U028	0.030
U049	0.030
U034	0.025
U019	0.025
U050	0.025
U038	0.025

```
df['user_id'].value_counts(normalize=True)
```

U000	0.025
U025	0.025
U023	0.025
U008	0.025
U013	0.025
U041	0.025
U021	0.025
U004	0.020
U022	0.020
U001	0.020
U033	0.020
U014	0.020
U015	0.020
U031	0.020

Рис. 5 Подсчет уникальных значений user_id




Рис. 6 Круговая диаграмма распределения id пользователей

Пол пользователя (**gender**) является категориальным признаком, представляющим гендерную принадлежность пользователей фитнес-трекера. В данном столбце отсутствуют пропуски. Всего в датафрейме представлено 3 гендерные категории. Распределение по гендерным группам практически равномерное. Наиболее представленной категорией являются женщины (Female) - 34.5% от всех записей (69 записей). Категория "Other" следует с 34% (68 записей). Мужчины (Male) представлены 31.5% записей (63 записи). Разница между наиболее и наименее представленными группами составляет всего 3%.


```
df['gender'].describe()
```

gender	
count	200
unique	3
top	Female
freq	69

dtype: object

Рис. 7 Описание признака gender

```
df['gender'].value_counts()
```

count	
gender	
Female	69
Other	68
Male	63

dtype: int64

```
df['gender'].value_counts(normalize=True)
```

proportion	
gender	
Female	0.345
Other	0.340
Male	0.315

dtype: float64

Рис. 8 Подсчет уникальных значений пола




Рис. 9 Круговая диаграмма распределения пола

Тип физической активности является категориальным признаком, представляющим различные виды тренировок пользователей фитнес-трекера. В данном столбце отсутствуют пропуски. Всего в датафрейме представлено 7 различных типов физической активности. Распределение по типам активностей показывает явного лидера - йогу (Yoga), которая составляет 21% от всех записей (42 тренировки). Второе место занимает ходьба (Walking) с 15% (30 записей). Группа из трех активностей - силовые тренировки (Strength Training), высокоинтенсивные интервальные тренировки (HIIT) и плавание (Swimming) - имеют одинаковую популярность по 13.5% каждая (по 27 записей). Бег (Running) составляет 12% (24 записи), а велоспорт (Cycling) завершает список с 11.5% (23 записи). Разница между самым популярным (йога) и наименее популярным (велоспорт) видом активности составляет 9.5%.

```
df['activity_type'].describe()
```

activity_type	
count	200
unique	7
top	Yoga
freq	42

dtype: object

Рис. 10 Описание признака activity_type

```
df['activity_type'].value_counts()
```

activity_type	count
Yoga	42
Walking	30
Strength Training	27
HIIT	27
Swimming	27
Running	24
Cycling	23

dtype: int64

```
df['activity_type'].value_counts(normalize=True)
```

activity_type	proportion
Yoga	0.210
Walking	0.150
Strength Training	0.135
HIIT	0.135
Swimming	0.135
Running	0.120
Cycling	0.115

dtype: float64

Рис. 11 Подсчет уникальных значений видов активности




Рис. 12 Круговая диаграмма распределения видов активности

5. Количественные признаки

Первым количественным признаком является возраст (**age**). Возраст пользователей в датасете варьируется от 16 до 69 лет. Средний возраст составляет 44,38 года, а медиана — 43 года, что означает, что половина пользователей моложе 43 лет. Первый квартиль равен 33 годам, то есть 25% пользователей имеют возраст 33 года или меньше, а третий квартиль — 58 лет, что указывает на то, что 75% пользователей моложе 58 лет. Стандартное отклонение, равное 15,42, показывает умеренный разброс значений относительно среднего. Наибольшая концентрация пользователей наблюдается в двух возрастных диапазонах: от 29,25 до 42,5 года и от 55,75 до 69 лет.

```
df['age'].describe()
```

	age
count	200.000000
mean	44.380000
std	15.417982
min	16.000000
25%	33.000000
50%	43.000000
75%	58.000000
max	69.000000

dtype: float64

Рис. 11 Описание признака age

```
df['age'].value_counts().head(10)
```

	count
age	
42	13
66	9
34	8
23	7
31	6
68	6
39	6
60	6
37	6
58	6

dtype: int64

```
df['age'].value_counts().head(10)
```

	count
age	
42	13
66	9
34	8
23	7
31	6
68	6
39	6
60	6
37	6
58	6

dtype: int64

Рис. 12 Подсчет уникальных значений возраста

Самое распространенное значение 42 встречается у 13 пользователей




Рис. 13 Группировка признака возраст




Рис. 14 гистограмма группировки признака возраст

Наибольшее количество пользователей имеют возраст в диапазонах 29,25-42,5 и 55,75-69. Наименьшее количество пользователей имеет возраст в диапазоне 15, 946 – 29,25.




Рис. 15 Гистограмма распределения признака возраст




Рис. 16 Блоксплот признака возраст

Распределение скошено вправо, выбросов нет.

Значения варьируются от 16 до 69

Среднее значение: 44.38

Медиана: 43 (50% пользователей имеют возраст 43 и ниже)

Первый квартиль: 33 (25% пользователей имеют возраст 33 и ниже)

Третий квартиль: 58 (75% пользователей имеют возраст 58 и ниже)

Стандартное отклонение от среднего значения: 15.42

Вторым количественным признаком является продолжительность тренировки в минутах (**duration_min**). Продолжительность тренировок пользователей варьируется от 5 до 119 минут. Средняя продолжительность составляет 64,025 минуты, при этом медиана равна 68 минутам, что означает, что половина пользователей тренируется 68 минут или меньше. Первый квартиль составляет 33 минуты, указывая на то, что 25% пользователей занимаются не более 33 минут, тогда как третий квартиль равен 95 минутам, то есть 75% пользователей тренируются до 95 минут. Стандартное отклонение 34,69 отражает значительный разброс в продолжительности тренировок.

Наибольшее количество пользователей сосредоточено в диапазоне от 95,5 до 119 минут, что свидетельствует о наличии группы пользователей с особенно длительными тренировками.


```
df['duration_min'].describe()
```

	duration_min
count	200.000000
mean	64.025000
std	34.693987
min	5.000000
25%	33.000000
50%	68.000000
75%	95.000000
max	119.000000

dtype: float64

Рис. 17 Описание признака duration_min

```
df['duration_min'].value_counts(bins=4).sort_index()
```

	count
(4.885, 33.5]	52
(33.5, 62.0]	37
(62.0, 90.5]	52
(90.5, 119.0]	59

dtype: int64

Рис. 18 Группировка по признаку продолжительности тренировки




Рис. 19 Гистограмма группировки по признаку продолжительности тренировки

По гистограмме видно, что наибольшее количество пользователей имеют продолжительность тренировок от 95.5 до 119 минут. Наименьшее количество пользователей тренируется от 33,5 до 62 минут.




Рис. 20 Гистограмма распределения признака продолжительность тренировки




Рис. 21 Блоксплот признака продолжительность тренировки

Распределение скошено вправо, признак не имеет выбросов.

Значения варьируются от 5 до 119

Среднее значение: 64.025

Медиана: 68 (50% пользователей имеют продолжительность 68 и ниже)

Первый квартиль: 33 (25% пользователей имеют продолжительность 33 и ниже)

Третий квартиль: 95 (75% пользователей имеют продолжительность 95 и ниже)

Стандартное отклонение от среднего значения: 34.69

Третьим количественным признаком является количество сожженных калорий (**calories_burned**). Количество сожженных калорий за тренировку варьируется от 50 до 585. Средний показатель составляет 295,765 калории, при этом медиана равна 311,5 калории, что означает, что половина пользователей сжигает 311,5 калории или меньше. Первый квартиль составляет 220 калорий, указывая на то, что 25% пользователей тратят не более 220 калорий за тренировку, тогда как третий квартиль равен 378 калориям, то есть 75% пользователей сжигают до 378 калорий. Стандартное отклонение 120 калорий отражает существенный разброс в энергозатратах между пользователями. Наибольшая концентрация пользователей наблюдается в диапазоне от 183,75 до 317,5 калории, что представляет собой наиболее типичный уровень энергозатрат во время тренировок.

```
df['calories_burned'].describe()
```

calories_burned	
count	200.000000
mean	295.765000
std	120.563834
min	50.000000
25%	220.000000
50%	311.500000
75%	378.000000
max	585.000000

dtype: float64

Рис. 22 Описание признака calories_burned

```
df['calories_burned'].value_counts(bins=4).sort_index()
```

	count
(49.464000000000006, 183.75]	34
(183.75, 317.5]	76
(317.5, 451.25]	72
(451.25, 585.0]	18

dtype: int64

Рис. 23 Группировка по признаку количество сожженных калорий




Рис. 24 Гистограмма группировки по признаку количество сожженных калорий

По гистограмме видно, что наибольшее количество пользователей за тренировку сжигает от 183,75 до 317,5 калорий. Наименьшее количество пользователей за тренировку сжигает от 451, 25 до 585 калорий.



Рис. 25 Гистограмма распределения признака количество сожженных калорий



Рис. 26 Блоксплот признака количество сожженных калорий

Признак не имеет выбросов, распределение скошено вправо

Значения варьируются от 50 до 585

Среднее значение: 295.765

Медиана: 311.5 (50% пользователей сжигают 311.5 калорий и меньше)

Первый квартиль: 220 (25% пользователей сжигают 220 калорий и меньше)

Третий квартиль: 378 (75% пользователей сжигают 378 калорий и меньше)

Стандартное отклонение от среднего значения: 120

Четвертым количественным признаком является средний пульс (**heart_rate_avg**). Средняя частота пульса пользователей во время тренировок варьируется от 60 до 179 ударов в минуту. Среднее значение составляет 120,935 уд/мин, при этом медиана равна 121 уд/мин, что означает, что у половины пользователей средний пульс не превышает 121 уд/мин. Первый квартиль составляет 89,75 уд/мин, указывая на то, что у 25% пользователей пульс во время тренировки составляет 89,75 уд/мин или меньше, тогда как третий квартиль равен 150,25 уд/мин, то есть у 75% пользователей средний пульс не превышает 150,25 уд/мин. Стандартное отклонение 34,1 уд/мин отражает значительный разброс показателей пульса между пользователями. Наибольшая концентрация пользователей наблюдается в диапазоне от 149,25 до 179 уд/мин, что соответствует высокой интенсивности тренировок для этой группы.

```
df['heart_rate_avg'].describe()
```

heart_rate_avg	
count	200.000000
mean	120.935000
std	34.100366
min	60.000000
25%	89.750000
50%	121.000000
75%	150.250000
max	179.000000

dtype: float64

Рис. 27 Описание признака heart_rate_avg

```
df['heart_rate_avg'].value_counts(bins=4).sort_index()
```

count	
(59.88, 89.75]	50
(89.75, 119.5]	49
(119.5, 149.25]	49
(149.25, 179.0]	52

dtype: int64

Рис. 28 Группировка по признаку средняя частота пульса




Рис. 29 Гистограмма группировки по признаку средняя частота пульса

По гистограмме видно, что наибольшее количество пользователей имеют частоту пульса от 59.88 до 89.75




Рис. 30 Гистограмма распределения признака средняя частота пульса




Рис. 31 Блоксплот признака средняя частота пульса

Признак Средняя частота пульса не имеет выбросов, распределение близко к нормальному

Значения варьируются от 60 до 179

Среднее значение: 120.935

Медиана: 121 (50% пользователей имеют пульс 121 и ниже)

Первый квартиль: 89.75 (25% пользователей имеют пульс 89.75 и ниже)

Третий квартиль: 150.25 (75% пользователей имеют пульс 150.25 и ниже)

Стандартное отклонение от среднего значения: 34.100366

Пятым количественным признаком является количество шагов (**steps**).

Количество пройденных шагов пользователями варьируется от 370 до 24 984 шагов в день. Среднее значение составляет 14 020 шагов, при этом медиана равна 14 857 шагов, что означает, что половина пользователей проходит 14 857 шагов или меньше. Первый квартиль составляет 9 585 шагов, указывая на то, что 25% пользователей проходят не более 9 585 шагов в день, тогда как третий квартиль равен 19 007 шагов, то есть 75% пользователей проходят до 19 007 шагов. Стандартное отклонение 6 428 шагов отражает значительный разброс в ежедневной активности пользователей. Наибольшая концентрация пользователей наблюдается в диапазоне от 12 677 до 18 830,5 шагов, что представляет собой наиболее типичный уровень ежедневной двигательной активности для данной группы пользователей.

```
df['steps'].describe()
```

	steps
count	200.00000
mean	14020.82000
std	6428.05981
min	370.00000
25%	9585.00000
50%	14857.00000
75%	19007.75000
max	24984.00000

dtype: float64

Рис. 32 Описание признака steps

```
df['steps'].value_counts(bins=4).sort_index()
```

	count
(345.38500000000005, 6523.5]	32
(6523.5, 12677.0]	48
(12677.0, 18830.5]	68
(18830.5, 24984.0]	52

dtype: int64

Рис. 33 Группировка по признаку шаги




Рис. 34 Гистограмма группировки по признаку шаги

По гистограмме видно, что наибольшее количество пользователей ходит от 12677.0 и до 18830.5 шагов. Наименьшее количество пользователей проходит от 6523.5 до 12677 шагов.




Рис. 35 Блоксплот по признаку шаги

Признак не имеет выбросов, распределение скошено вправо

Значения варьируются от 370 до 24984

Среднее значение: 14020


Медиана: 14857 (50% пользователей ходят 14857 шагов и меньше)

Первый квартиль: 9585 (25% пользователей ходят 9585 шагов и меньше)

Третий квартиль: 19007 (75% пользователей ходят 19007 шагов и меньше)

Стандартное отклонение от среднего значения: 6428

Шестым количественным признаком является количество часов сна (**sleep_hours**). Продолжительность сна пользователей варьируется от 3 до 9,5 часов в сутки. Среднее значение составляет 6,313 часа, при этом медиана равна 6,5 часа, что означает, что половина пользователей спит 6,5 часа или меньше. Первый квартиль составляет 4,775 часа, указывая на то, что 25% пользователей спят не более 4,775 часа в сутки, тогда как третий квартиль равен 7,9 часа, то есть 75% пользователей спят до 7,9 часа. Стандартное отклонение 1,9 часа отражает умеренный разброс в продолжительности сна между пользователями. Наибольшая концентрация пользователей наблюдается в диапазоне от 6,25 до 7,875 часа.



```
df['sleep_hours'].describe()
```

sleep_hours	
count	200.000000
mean	6.313000
std	1.911518
min	3.000000
25%	4.775000
50%	6.500000
75%	7.900000
max	9.500000

dtype: float64

Рис. 36 Описание признака sleep_hours

```
df['sleep_hours'].value_counts(bins=4).sort_index()
```

	count
(2.9930000000000003, 4.625]	48
(4.625, 6.25]	45
(6.25, 7.875]	55
(7.875, 9.5]	52

dtype: int64

Рис. 37 Группировка по признаку продолжительность сна




Рис. 38 Гистограмма группировки по признаку продолжительность

Наибольшее количество пользователей спят от 6.25 до 7.875 часов.
 Наименьшее количество пользователей спит от 4.625 до 6.25 часов.




Рис. 39 Гистограмма распределения признака продолжительность сна



Рис. 40 Блоксплот признака продолжительность сна

Признак не имеет выбросов, распределение скошено вправо

Значения варьируются от 3 до 9.5

Среднее значение: 6.313

Медиана: 6.5 (50% пользователей спят 6.5 часов и меньше)

Первый квартиль: 4.775 (25% пользователей спят 4.775 часов и меньше)

Третий квартиль: 7.9 (75% пользователей спят 7.9 часов и меньше)

Стандартное отклонение от среднего значения: 1.9

Седьмым количественным признаком является масса тела (**weight_kg**). Вес пользователей варьируется от 35,3 до 105,2 кг. Средний вес составляет 70,152 кг, при этом медиана равна 70,6 кг, что означает, что половина пользователей

имеет массу тела 70,6 кг или меньше. Первый квартиль составляет 61,45 кг, указывая на то, что 25% пользователей весят не более 61,45 кг, тогда как третий квартиль равен 80,1 кг, то есть 75% пользователей имеют массу тела до 80,1 кг. Стандартное отклонение 14,13 кг отражает значительный разброс показателей веса между пользователями. Наибольшая концентрация пользователей наблюдается в диапазоне от 70,25 до 87,725 кг.

```
df['weight_kg'].describe()
```

	weight_kg
count	200.000000
mean	70.152000
std	14.129562
min	35.300000
25%	61.450000
50%	70.600000
75%	80.100000
max	105.200000

dtype: float64

Рис.41 Описание признака weight_kg

```
df['weight_kg'].value_counts(bins=4).sort_index()
```

	count
(35.229, 52.775]	21
(52.775, 70.25]	77
(70.25, 87.725]	82
(87.725, 105.2]	20

dtype: int64

Рис. 42 Группировка по признаку масса тела




Рис. 43 Гистограмма группировки по признаку масса тела

По гистограмме видно, что наибольшее количество пользователей имеют массу тела от 70.25 до 87.725 кг. Наименьшее количество пользователей имеет массу тела от 87.725 до 105.2 кг.




Рис. 44 Гистограмма распределения по признаку масса тела




Рис. 45 Блоксплот признака масса тела

Признак выбросов не имеет, распределение скошено влево

Значения варьируются от 35.3 до 105.2

Среднее значение: 70.152

Медиана: 70.6 (50% пользователей имеют массу тела 70.6 и меньше)

Первый квартиль: 61.45 (25% пользователей имеют массу тела 61.45 и меньше)

Третий квартиль: 80.1 (75% пользователей имеют массу тела 80.1 и меньше)

Стандартное отклонение от среднего значения: 14.13

